Mondragon Unibertsitatea

Faculty of Engineering

Datuen Ingeniaritza

- Data Engineering -

- Ingeniería de Datos -

1.3

Datu Kodifikazioa

Datu Kodifikazioa

Informazioa edo datuak formatu zehatz batetara bilakatzeko prozesua

- Prozesu honek datuak bidali edo gordetzean informazioa aldatu gabe edo galera gabe mantentzen dela zihurtatzen du
  - Nahiz eta datu kodifikazio estrategiaren arabera informazioa galdu dezakegun

- Abantailak (kodifikazio formatuaren arabera)
  - Biltegiratze espazioa
  - Irakurtzea, idazte edo bidalketa abiadura
  - Datu kantitate txikientzat baztergarria
    - Datu kantitate handien inguruan hitz egiten dugunean, datu kodifikazioak eragin handia izan dezake

Datu Kodifikazioa

- Byte = 8 bit ?
  - Hasierako byte definizioa (Werner Buchholz 1956)
    - Sistema informatiko batean textu karaktere bat kodifikatzeko beharrezko bit kopurua
      - Baita prozesagailuak helbideratu dezakeen memoria unitate txikiena (azken hau aurrekoaren arabera diseinatzen zelarik)
    - Historikoki 6, 7, 9 eta 12 bit-eko byte-ak ere existitu dira
  - Gaur egungo byte = 8 bit definizioaren zergatia
    - IBM-k 1964an 8 bit-eko byte-a erabiltzen zuen System/360 ordenagailu familia kaleratu zuen
      - 8 bit erabiliz byte bakarrean bi zenbaki hamartar gorde zitzakeen (Binary-Coded Decimal)
      - Ordenagailu familia honen arrakastak industria mailan 8 bit = 1 byte ezartzea ekarri zuen
    - 8 zenbakia 2 zenbakiaren berretura (potencia) izanik, hardware diseinua matematikoki efizienteagoa eta eleganteagoa izatea dakar

- Octeto vs Byte
  - Hasieran byte terminoak bit ezberdin kopuru bat adierazi zezakeenez, telekomunikazio ingeniariek “octeto” hitza sortu zuten
    - Hori dela eta sare estandare internazionaletan “octeto” hitza erabili izan da, adibidez IP helbidearen definizioan

Datu Kodifikazioa

- Kodifikazioa mota ezberdinetako datuei aplikatzeko aukera dago
  - Textua
  - Irudiak
  - Audioa
  - Bideoak
  - …

- Datu kodifikazio eskema ugari daude, besteak beste (1/3)
  - ASCII
    - *American Standard Code for Information Interchange*, zaharretarikoa eta erabilienetarikoena
    - 7 bit-eko byte-etan 128 karaktere zehatz kodifikatzen ditu
      - Ingeleseko karaktere guztiak (handiak, txikiak), zenbakiak, puntuazio markak eta kontrol komandoak (orga-itzulera) adierazteko nahikoa
  - Unicode
    - Karaktere kodifikazio estandare unibertsala
    - Karaktere bakoitzari zenbaki bakar eta aldaezin bat esleitzen dio
      - Plataforma, gailu, aplikazio edo lengoaiak ez du eragiten, ez da hauen menpekoa

Datu Kodifikazioa

- Datu kodifikazio eskema ugari daude, besteak beste (2/3)
  - UTF-8
    - Zabalera aldakorreko karaktere kodifikazio eskema
    - Unicode karaktere denak kodifikatzeko gai da
    - ASCII karaktere denak aldaketa gabe kodifikatzeko gai da
    - Adibidea
      - ñ hizkia/karakterea
        - Unicode balioa: U+00F1
          - 0 0 F 1
          - 0000 0000 1111 0001
        - UTF-8 balioa: C3B1 (Hex - hameseitarra)
          - C 3 B 1
          - 1100 0011 1011 0001
  - Kodifikazio bitarra
    - Datuak 2-oinarrian adierazten dituen eskema sinplea
  - Base64
    - Bitarretik texturako kodifikazio sistema
    - Datu bitarrak ASCII bidezko karaktere kate batera bilakatzen ditu

Datu Kodifikazioa

- Datu kodifikazio eskema ugari daude, besteak beste (3/3)
  - Morse kodea
    - Datu kodifikazio sistema zaharrenetarikoa
    - Hizki, zenbaki eta puntuazioa puntu eta lerroen bidez adierazten dira

- Datu kodifikazioa bi talde handitan banatu daiteke
  - Textu formatoak
  - Formato bitarrak

Datu Kodifikazioa

- Textu formato ugari existitzen dira, hala nola
  - JSON (*JavaScript Object Notation*)
    - Arina eta irakurterraza
    - Web ingurunetan asko erabiltzen da
    - Datuen eskema zehaztu daiteke
    - Integer eta float motako zenbakiak ez dira bereizten
  - XML (eXtensible Markup Language):
    - Datu konplexuak irudikatzeko ezaugarrietan aberatsa
    - Izen espazioak erabili eta eskema zehaztu daiteke
    - Zenbaki eta textu kateak ezin daiteezke bereiztu
  - CSV (Comma-Separated Values):
    - Sinplea eta eraginkorra taula datuetarako
    - Kalkulu-orrietara eta datu-baseetara erraz inporta daiteke
    - Zenbaki eta textu kateak ezin daitezke bereiztu
  - YAML (YAML Ain't Markup Language):
    - Irakurterraza
    - Egitura habiaratua (anidado) behar duten konfigurazio eta datu-fitxategietarako egokia

Datu Kodifikazioa

- Formatu bitarrak
  - Eskemetan oinarritzen diren formatuak daude
    - Datuak eskemaren arabera dekodifikatu behar dira gizakiok ulertu aurretik
  - Kodifikazio konpaktu eta efizientea ahalbidetzen dute
  - Aukera asko daude, esaterako
    - Apache Thrift
      - Hasiera batean Facebook-ek garatua
    - Apache Avro
      - Apache Hadoop-en azpiproiektua, Apache Thrift-en mugei aurre egiteko
      - Dinamikoki sortutako datu eskemekin lan egin dezake
    - Protocol Buffers
      - Hasiera batean Google-en garatua
  - Ondorengo datuak kodifikatzea nahi ditugu formatu ezberdinetan
    - Martin
    - 1337
    - [daydreaming, hacking]

Datu Kodifikazioa

- Formatu bitarrak
  - Apache Thrift

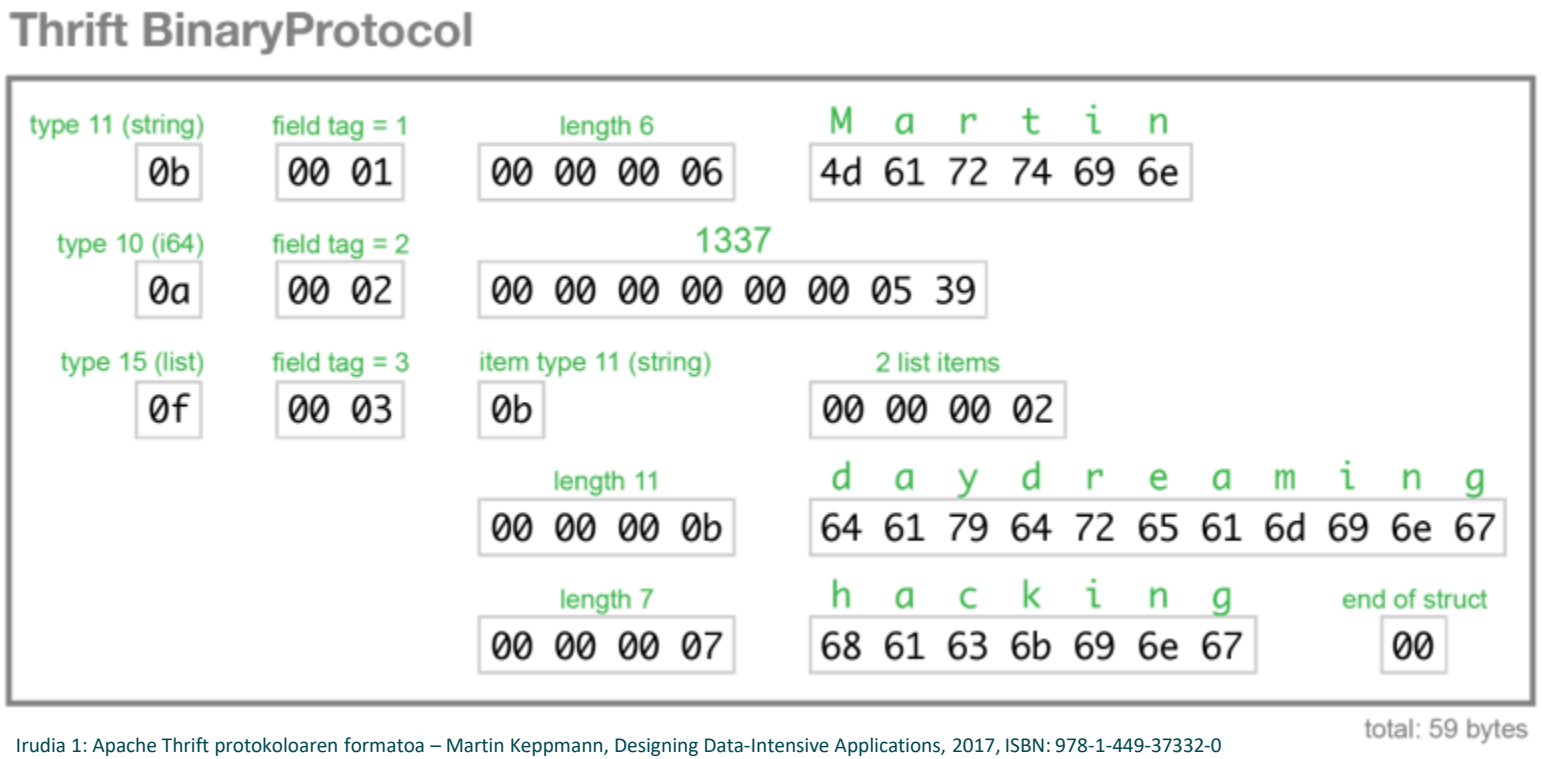

Irudia 1: Apache Thrift protokoloaren formatoa – Martin Keppmann, Designing Data-Intensive Applications, 2017, ISBN: 978-1-449-37332-0

Datu Kodifikazioa

- Formatu bitarrak
  - Protocol Buffers

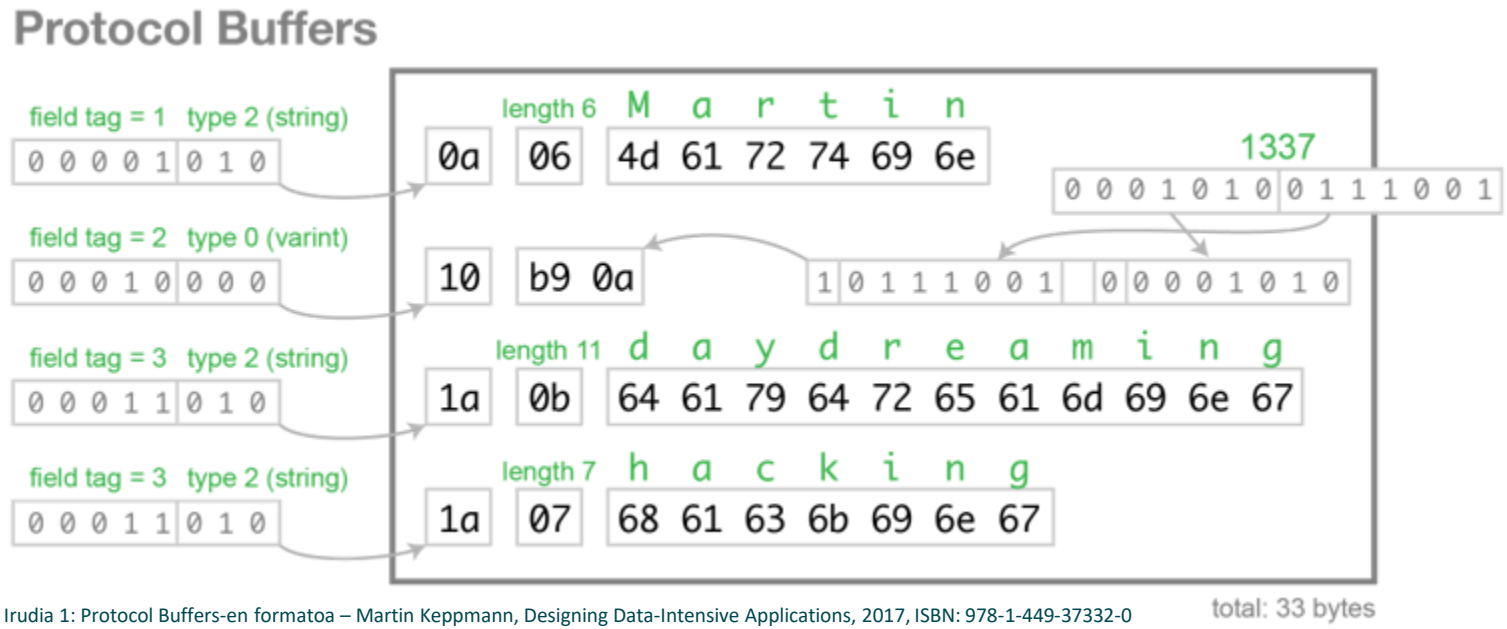

Irudia 1: Protocol Buffers-en formatoa – Martin Keppmann, Designing Data-Intensive Applications, 2017, ISBN: 978-1-449-37332-0

Datu Kodifikazioa

- Formatu bitarrak
  - Apache Thrift eta Protocol Buffers
    - Eskema eguneratu daiteke ondorengo erregelak jarraituz
      - Tag-ak bakarrak dira eta ezin daitezke aldatu
        - Eremu berri bakoitzak eremu zenbaki (tag) berri bat izan behar du
        - Eremu berri bakoitza aukerakoa izan behar da edo defektuzko balio bat izan behar du
      - Aukerazkoak diren eremuak bakarrik ezabatu daitezke
      - Datu mota batzuen eguneraketak aurrera eraman daitezke
        - Esaterako 32 bit-eko integer bat 64 bit-eko batean bilakatu

Datu Kodifikazioa

- Formatu bitarrak
  - Apache Avro

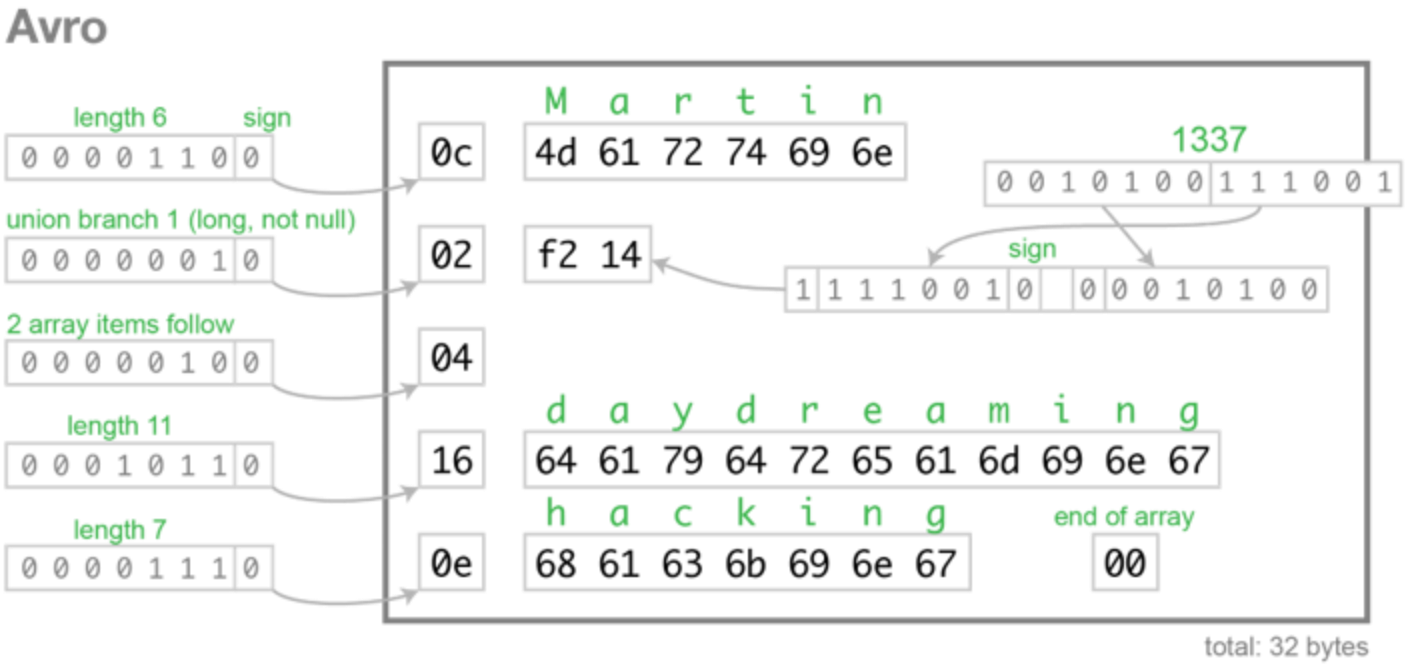

Irudia 1: Apache Avro protokoloaren formatoa – Martin Keppmann, Designing Data-Intensive Applications, 2017, ISBN: 978-1-449-37332-0

Datu Kodifikazioa

- Formatu bitarrak
  - Apache Avro
    - Eskema dinamikoki sortu daiteke
      - Ez daude tag zenbakiak
      - Idatzi eta irakurtzen duten prozesuen eskemak ez dute berdinak izan beharrik
      - Kodifikazioan baloreak bata bestearen jarraian jartzen dira
      - Eremu denek defektuzko baloreak dituzte
        - Eskema eguneratze arazoak ekinidez

Ariketa 13

Mondragon Unibertsitatea
Faculty of Engineering

Eskerrik asko
Thank you

Iñaki Garitano
igaritano@mondragon.edu

Data Analysis and Cybersecurity Research Group
Telematics and Cybersecurity Area
Electronics and Computing Department
Mondragon University - Faculty of Engineering
Goiru, 2; 20500 Arrasate - Mondragon (Gipuzkoa), Spain
Tel. : +(34) 647503682 / +(34) 943794700 + Ext. 8119